

**Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie**

Wydział Geologii Geofizyki i Ochrony Środowiska



PRACA INŻYNIERSKA

Temat: Automatyczna delineacja pól uprawnych za pomocą metod uczenia maszynowego i obrazowań satelitarnych

Imię i nazwisko: Piotr Powroźnik

Kierunek studiów: Geoinformatyka

Opiekun pracy: dr inż. Michał Lupa

Kraków, rok Akadem. 2024/2025

Spis treści

1.	WSTĘP	3
2.	MATERIAŁY	4
2.1	SEGMENT ANYTHING MODEL 2	4
2.2	GOOGLE EARTH ENGINE	6
2.2.1	<i>National Agriculture Imagery Program (NAIP).....</i>	<i>6</i>
2.2.2	<i>Sentinel-2.....</i>	<i>7</i>
2.2.3	<i>Landsat 8.....</i>	<i>7</i>
2.2.4	<i>ESA WorldCereal Active Cropland.....</i>	<i>7</i>
2.3	FIELDS OF THE WORLD	8
3.	METODYKA	9
3.1	DOTRENOWANIE MODELI	9
3.2	SEGMENTACJA I DELINEACJA	13
4.	WYNIKI	16
4.1	NAIP	17
4.2	SENTINEL-2	20
4.3	LANDSAT 8.....	23
5.	WNIOSKI	28
	LITERATURA	31

1. Wstęp

Współczesne rolnictwo staje w obliczu wielu wyzwań w postaci rosnącej liczby ludności, zmian klimatycznych, degradacji gleby oraz klęsk żywiołowych. Kluczowym okazuje się wykorzystanie metod precyzyjnego rolnictwa do monitoringu jakości plonów, stanu gleby czy optymalizacji procesu nawożenia i ochrony roślin w postaci oprysków. Stały monitoring upraw związany jest z koniecznością wyznaczania granic pól uprawnych. Ręczna delineacja (wektoryzacja) granic pól uprawnych przy wykorzystaniu oprogramowania GIS jest procesem kosztownym czasowo, w związku z tym zastosowanie automatycznych metod wykorzystujących złożone algorytmy lub modele uczenia maszynowego zyskuje na znaczeniu w wyznaczaniu pól uprawnych.

Celem niniejszej pracy inżynierskiej jest analiza narzędzia w postaci modelu Segment Anything Model 2 (SAM 2) w segmentacji i następnej delineacji pól uprawnych na zdjęciach satelitarnych. Analiza opiera się na porównaniu wyników działania modelu SAM 2 w zależności od przyjętych parametrów, takich jak rozdzielczość przestrzenna pikseli zdjęcia oraz rodzaj modelu SAM 2. Uzyskane wyniki mogą pozwolić na ocenę opłacalności stosowania danych wysokorozdzielczych czy modeli o większym poziomie skomplikowania oraz na polepszenie i przyspieszenie wyznaczania geometrii upraw.

2. Materiały

W niniejszej pracy kluczowe znaczenie miało przygotowanie odpowiednich materiałów, które umożliwiłyby przeprowadzenie analizy delineacji pól uprawnych. W celu analizy wykorzystano trzy zobrazowania o różnych rozdzielczościach przestrzennych. Do segmentacji zobrazowań satelitarnych wykorzystano cztery wersje modelu SAM 2. Do do-trenowania modelu SAM 2 posłużono się zbiorem danych treningowych Fields of The World (FTW), umożliwiającym dostosowanie modeli do segmentacji pól uprawnych. W procesie analizy skorzystano także z odpowiednich danych referencyjnych stanowią-cych punkt odniesienia dla oceny dokładności delineacji pól uprawnych. Charakterystyka wykorzystanych materiałów została przedstawiona w dalszej części rozdziału.

2.1 Segment Anything Model 2

Segment Anything Model 2 [6] jest modelem uczenia maszynowego stworzonym do przeprowadzania segmentacji obiektów zarówno na zdjęciach jak i na filmach. SAM 2 jest już drugą, zaprezentowaną w 2024 roku, wersją modelu. Wytrenowany został na zbiorze danych zawierającym 11 milionów zdjęć a także na danych w postaci filmów. Od jego poprzednika [3] wyróżnia go rozbudowana architektura o elementy umożliwia-jące działanie na filmach oraz większa dokładność jaki i szybkość. Architektura modelu (Fig. 2.2) składa się z następujących elementów:

- Image encoder – rolą enkodera zdjęć jest redukcja wymiarów zdjęcia i stwo-rzenie matematycznej reprezentacji dyskretnego obrazu w postaci osadzenia jego właściwości (feature embedding) [11], które będzie mogło być przetwo-rzone przez model.
- Memory attention – podczas segmentacji filmu powiązuje bieżącą klatkę z in-formacjami pochodzącymi z segmentacji poprzednich klatek filmu, w celu uspołnienia informacji.
- Prompt encoder – enkoder danych wejściowych pozwala na interakcję z mo-delem, poprzez zapewnienie mu informacji w postaci punktów, masek lub

tekstu. Punkty oraz ramki konwertowane są do wektorów zawierających informację o lokalizacji oraz w przypadku punktów informacji czy reprezentuje tło czy obiekt. Maska osadzana jest za pomocą konwolucyjnej sieci neuronowej.

- Mask decoder – kluczowy element modelu, generuje maski na podstawie osadzeń stworzonych przez enkodery. Na wejściu przyjmuje zakodowane zdjęcia oraz informacje zakodowane przez prompt encoder w postaci tokenów. Następnie dane trafiają do dwóch takich samych warstw, każda z nich wykonuje 4 operacje. Wśród tych operacji znajduje się użycie sieci mlp oraz mechanizmów self-attention i cross-attention. Wynikiem tych operacji jest zaktualizowanie osadzenia zdjęcia i tokenów, które trafiają jako dane wejściowe do drugiej takiej samej warstwy. Końcowe osadzenia wykorzystywane są do stworzenia masek segmentacji, obliczenia wartości IoU i okluzji, mającej zastosowanie przy segmentacji filmów by ocenić czy na klatce znajduje się obiekt.




Fig 2.1 Schemat architektury dekodera masek, źródło: [6].

- Memory encoder i memory Bank – mają zastosowanie przy segmentacji filmów. Encoder pozwala na zakodowanie informacji pochodzących z poprzednich segmentacji i zapisanie ich banku pamięci. Informacje zawarte w banku pamięci wykorzystane będą podczas przetwarzania kolejnych klatek filmu w bloku memory attention.




Fig. 2.2 Schemat architektury SAM 2, źródło: [6].

2.2 Google Earth Engine

Google Earth Engine (GEE) stanowi platformę obliczeniową umożliwiającą użytkownikom przeprowadzanie analiz geoprzestrzennych wykorzystując infrastrukturę Google [8]. Jedną z kluczowych funkcji GEE jest dostęp do katalogów z różnorodnymi danymi rastrowymi; poprzez środowisko dostępne są m.in. zdjęcia z optycznych oraz radarowych misji satelitarnych, klasyfikacyjne mapy pokrycia terenu, dane geofizyczne czy też informacje o zmianach klimatycznych. Korzystanie z GEE możliwe jest poprzez wykorzystanie webowego API lub stworzonych bibliotek Python. Jedną z takich bibliotek jest Geemap opracowany przez dr. Qiusheng Wu. Geemap [9], ułatwia on korzystanie z GEE w sposób interaktywny w środowisku notatników Jupyter.

W niniejszej pracy wykorzystano bazę danych udostępnioną przez środowisko GEE do przeprowadzenia analizy trzech dostępnych przez nie zobrazowań, o różnych rozdzielczościach przestrzennych. W celu porównawczych skorzystano także z danych referencyjnych przedstawiających pola uprawne. W dalszej części przedstawiono wszystkie programy, w ramach których dostarczane są wykorzystane w analizie dane.

2.2.1 National Agriculture Imagery Program (NAIP)

Zarządzany przez rząd Stanów Zjednoczonych program obrazowania obszarów rolniczych. NAIP udostępnia wysokorozdzielcze dane lotnicze pozyskiwane w czasie sezonów wegetacyjnych w kontynentalnych Stanach Zjednoczonych. Od 2018 roku dane pozyskiwane są w rozdzielczości 0.6 m w 4 kanałach (RGBN), starsze zdjęcia posiadają niższą rozdzielczość 1 lub 2 metrową oraz tylko 3 kanały (RGB). Procent zachmurzenia

każdego indywidualnego kafelka nie przekracza 10%. Jakość danych NAIP kontrolowana jest za pomocą automatycznych i wizualnych metod, w celu zapewnienia odpowiedniej jakości danych stosuje się także miarę absolutnej dokładności wiążącą zdjęcia z naziemnymi punktami kontrolnymi.

2.2.2 Sentinel-2

Satelity Sentinel-2 dostarczają multispektralne zobrażenia, których rozdzielczość spektralna zaczyna się od 10 m a kończy na 60 m. Satelity są częścią europejskiego programu Copernicus, mającego na celu pozyskiwanie i dostarczanie wysokiej jakości danych monitorujących Ziemię. Konstelacja satelitów Sentinel-2 składa się z dwóch takich samych satelitów, 2A i 2B, o wspólnej orbicie, ale przesuniętych w fazie o 180°. Do konstelacji w 2024 roku dołączył trzeci satelita 2C który ostatecznie ma zastąpić obecnie działający 2A [13].

2.2.3 Landsat 8

Landsat 8 jest należący do Stanów Zjednoczonych satelitą dostarczającym multispektralne zobrażenia ziemi. Satelita swoje działanie rozpoczął w 2013 roku w ramach programu obserwacji ziemi Landsat [12], dostarczającego globalne dane multispektralne. W jego konstrukcji wykorzystano dwa sensory: OLI zbierający dane w pasmach optycznych oraz bliskiej i średniej podczerwieni. Drugi sensor TIRS służy do pomiaru pasma termalnej podczerwieni. Rozdzielczość przestrzenna pikseli dla sensora OLI wynosi 30 m (oprócz pasma panchromatycznego), w przypadku sensora TIRS jest to 100 m.

2.2.4 ESA WorldCereal Active Cropland

Mapy upraw tworzona przez Europejską Agencję Kosmiczną (ESA) przedstawiająca obszary rolnicze w postaci warstwy rastrowej dostępnej dla całego świata. Dane zostały opracowane przy użyciu algorytmów klasyfikacyjnych bazujących na danych satelitarnych w postaci różnorodnych indeksów, danych radarowych charakteryzujących sposób odbicia fali i obliczonego na ich podstawie wegetacyjnego indeksu radarowego RVI, cyfrowego modelu terenu a także lokalizacji. Algorytm tworzenia map upraw uwzględniał zmianę tych parametrów w czasie w zależności od sezonu i cyku rozwoju upraw [7].

2.3 Fields of The World

Zbiór danych Fields of The World (FTW) zaprojektowany został do oraz analizy dokładności oraz trenowania oraz modeli uczenia maszynowego służących do segmentacji pól uprawnych na zdjęciach satelitarnych. FTW obejmuje 24 kraje na 4 kontynentach, zbiór danych składa się z 70 462 instancji z których każda zawiera wielospektralne zdjęcie satelitarne z satelity Sentinel-2 oraz odpowiadającej mu binarnej maski segmentacji. Dane te zostały opracowane zostały opracowane w sposób uwzględniający różne czynniki klimatyczne oraz zmienność pól uprawnych w zależności od sezonu i lokalizacji geograficznej, dzięki temu zbiór FTW może usprawnić działanie modeli segmentacji na całym świecie [2].

3. Metodyka

Przeprowadzenie analizy modelu SAM 2 wymagało uprzedniego zaplanowania przebiegu procesu badawczego, który pozwalał na ocenę dokładności delineacji pól uprawnych przy wykorzystaniu zarówno podstawowych jak i dotrenowanych modeli. Proces badawczy obejmował dotrenowanie czterech wersji modelu i następne wykorzystanie ich, oraz podstawowych wersji, do delineacji pól uprawnych na trzech obrazowaniach o różnych rozdzielczościach przestrzennych. Metodyka procesu badawczego uwzględniała etapy pobierania i wstępnego przetwarzania danych, dotrenowania modeli, segmentację, delineację oraz etapy weryfikacyjne. Wszystkie etapy procesu badawczego przedstawiono na poniższej grafice (Fig 3.1).




Fig 3.1 Schemat etapów procesu delineacji pól uprawnych.

3.1 Dotrenowanie modeli

W celu poprawy wyników segmentacji przy użyciu modelu SAM 2 postanowiono dotrenować każdą z czterech wersji modelu na danych FTW. Dotrenowanie modelu ma spowodować polepszenie działania modelu na danych satelitarnych. Użycie dotrenowanego modelu w celu segmentacji pól uprawnych powinno skutkować poprawą dokładności oraz uzyskaniem masek o bardziej realistycznych kształtach. Dotrenowanie bazowych wag modelu w przeciwieństwie do trenowania od zera wymaga mniejszych zasobów czasowych i obliczeniowych.

Proces dotrenowania modeli rozpoczęto od pobrania danych FTW. Spośród danych z 24 krajów wybrano te dostępne dla Szwecji. Dane zbierane w ramach programu FTW cechują się różną jakością w zależności od państwa. Na poniższym zdjęciu (Fig 3.2) przedstawiono zestawienie części danych z Holandii i ze Szwecji. Można zauważyć, że w przypadku Holandii znaczna część pól uprawnych nie została wyznaczona, natomiast w danych pochodzący ze Szwecji pominięte pola uprawne zdarzają się sporadycznie.



Fig 3.1 Zestawienie danych z Holandii (po lewej) z danymi ze Szwecji (po prawej).

Pobrane dane ze Szwecji składają się z 4760 zdjęć satelitarnych oraz przynależących do nich masek binarnych. Z danych odfiltrowano maski na których nie znajdują się pola uprawne, co dało 4180 par zdjęć oraz ich masek.

Dane następnie zostały wstępnie przetworzone. Na maskach została przeprowadzona operacja w postaci otwarcia morfologicznego obiektem strukturalnym będącym kwadratem o rozmiarze 3 pikseli. Otwarcie morfologiczne [5], będące połączeniem operacji erozji i następnej dyfuzji zdjęcia, pozwala na pozbycie się regionów jedno lub kilku pikselowych, które mogą zakłócić przebieg uczenia modelu. Do trenowania modelu przygotowano dane wejściowe w postaci punktów reprezentujących pola uprawne. Ponieważ dane FTW nie zawierają punktów wyznaczono je na podstawie dostępnych masek. Na każdej z masek przeprowadzono erozję, takim samym obiektem strukturalnym jak podczas ich przygotowania, a następnie dla każdego z regionów na masce wyznaczono po 2 losowo wybrane punkty. Zastosowanie erozji miało zapewnić, że punkty nie będą znajdować się na granicy regionów. Zdjęcia satelitarne zostały przeskalowane poprzez podzielenie ich przez współczynnik skali Sentinel-2 oraz ograniczono wartości w pikselach do 98 percentyla by usunąć wartości odstające. Konieczna była też konwersja zdjęcia do formatu

unsigned int 8. W tym celu znormalizowano wartości pikseli do przedziału 0-1 i następnie przeskalowano do formatu unsigned int 8. Przetworzone zdjęcie wraz z maską i losowymi punktami przedstawiono poniższej figurze (Fig 3.3).




Fig 3.2 Zdjęcie Sentinel-2 oraz maska wraz z losowo wyznaczonymi punktami.

Przygotowane dane zostały podzielone na dwa zbiory, zbiór treningowy stanowiący 80% całości oraz testowy obejmujący 20%.

W następnym kroku przystąpiono do trenowania modelu [14]. W tym celu pobrano 4 podstawowe wersje SAM 2. Zdecydowano się na dotrenowanie trzech części architektury modelu tj. mask decoder, prompt encoder oraz image encoder. Każda z wersji modelu dotrenowana była z takimi samymi parametrami. Do trenowania użyto optymalizatora AdamW [4], początkowy współczynnik uczenia wynosił 0.0001, wraz z każdą kolejną epoką zmniejszany był o 5% względem poprzedniej. Trenowanie odbyło się w 15 epokach, każda z nich miała 500 kroków. W każdym kroku wczytany został losowy zestaw danych treningowych. Następnie przeprowadzono segmentację zdjęcia, obliczono funkcję straty. Wagi modelu aktualizowano co 2 iterację. Po dotrenowaniu każdej wersji SAM 2 zapisano zaktualizowane wagi w celu późniejszego użycia. Dokładność modeli podczas trenowania została przedstawiona na wykresie (Fig 3.4).




Fig 3.4 Dokładność modeli podczas dotrenowania.

Działanie dotrenowanych wersji modelu zostało sprawdzone na danych testowych, aby ocenić ich skuteczność. W ramach sprawdzenia działania modeli wczytano losowe zdjęcie i następnie przeprowadzono segmentację przy pomocy modelu przed oraz po dotrenowaniu. Porównanie wyników segmentacji wszystkich czterech modeli przedstawiono na jednej figurze (Fig 3.5).




Fig 3.5 Porównanie segmentacji przy użyciu dotrenowanych modeli i ich podstawowych wersji.

3.2 Segmentacja i delineacja

Analizę modelu SAM 2 rozpoczęto od wyboru obszaru zainteresowania. Obszar wybrano tak by znajdowały się na nim tereny rolnicze oraz by możliwy był na nim dostęp, przez środowisko GEE, zarówno do wysokorozdzielczych zobrazowań, jak i do zdjęć o małej

rozdzielczości oraz danych porównawczych. Wybrany obszar zlokalizowany jest w USA w stanie Illinois, 30 km w kierunku zachodnim od Chicago. Wymiary obszaru wynoszą w przybliżeniu 12,5 km na 11,1 km, co daje powierzchnię bliską 139 km².

Dla zadanego obszaru pobrano przy użyciu funkcji „ee.ImageCollection” w środowisku GEE trzy zdjęcia w kanałach RGB, pochodzące z okresu od 1.01.2020 do 31.12.2021. Wczytanie danych zawierało także ich odpowiednie przetworzenie w celu uzyskania wyższej jakości.

- Sentinel-2 – Wykorzystana kolekcja obrazowań „COPERNICUS/S2_SR_HARMONIZED” została odfiltrowana ze zdjęć o zachmurzeniu przekraczającym 20%, z pozostałych chmury zostały usunięte za pomocą funkcji maskującej korzystającej z kanału „QA60”. Ostateczne zdjęcie zostało obliczone jako mediana wartości z całej kolekcji. Powstałe zdjęcie zostało przeskalowane poprzez podzielenie jego wartości przez współczynnik skali Sentinel-2, wynoszący 10 000. Zdjęcie przycięto do zadanego obszaru i podzielono na zachodzące na siebie kafle o wymiarze 500x500 pikseli.
- Landsat 8 – Wczytane dane z kolekcji „LANDSAT/LC08/C02/T1_L2” prze-filtrowane zostały do zadanego okresu. Z obrazowań przy wykorzystaniu kanału „QA_PIXEL” zamaskowane zostały chmury. Następnie wartości zdjęcia zostały przeliczone przy wykorzystaniu współczynników skali Landsat 8, kanały optyczne przemnożone zostały przez współczynnik skali 2.75e-05, a następnie odjęto od nich wartość offsetu wynoszącą 0,2. Z powstałych obrazowań wybrano kanały RGB i obliczono zdjęcie jako medianę. Zdjęcie pocięto na nakładające się kafle o wymiarze 1000x1000.
- NAIP – Dane wczytano z kolekcji „USDA/NAIP/DOQQ”. Kolekcja ta nie wymaga znacznego przetwarzania, zachmurzenie deklarowane przez dostawcę danych nie przekracza 10% oraz dane nie posiadają kanału z informacją o zachmurzeniu. Obrazowania zostały przefiltrowane do zadanego okresu oraz wybrano z nich kanały optyczne RGB, następnie zdjęcie zostało stworzone jako mediana z wszystkich wartości. Obrazowanie zostało przycięte do obszaru zainteresowania i przekonwertowane do formatu unsigned

int 8. Zdjęcie podzielono na zachodzące na siebie kafle o rozmiarze 3000x3000 pikseli.

Po pobraniu danych przystąpiono do porównania działania modeli SAM 2. Segmentację każdego z trzech zdjęć przeprowadzono z wykorzystaniem czterech podstawowych wariantów modelu oraz ich dotrenowanych wersji. Do delineacji zastosowano pakiet Samgeo [9] stworzony do przeprowadzania segmentacji zdjęć satelitarnych z udziałem modelu SAM 2. Każdorazowo proces segmentacji przeprowadzano z takimi samymi parametrami (Fig 3.6), dobranymi na podstawie wstępnej segmentacji wykonanej na zdjęciu Sentinel-2. Segmentację wykonano na zdjęciach w postaci kafelków, wynikowe maski binarne zostały następnie połączone i zdelinealizowane do postaci wektorowej. Proces delineacji zdjęć odbywał się w środowisku Google Colab przy wykorzystaniu układu graficznego T4 o 15 gigabajtach pamięci.

```
Sam2 = SamGeo2(  
    model_id=model_id,  
    automatic=True,  
    output_mode='binary_mask',  
    points_per_side=32,  
    points_per_batch=64,  
    pred_iou_thresh=0.7,  
    stability_score_thresh=0.80,  
    stability_score_offset=0.7,  
    crop_n_layers=1,  
    box_nms_thresh=0.7,  
    crop_n_points_downscale_factor=2,  
    min_mask_region_area=50.0,  
    use_m2m=True  
)
```

Fig 3.6 Parametry segmentacji.

Wyniki zostały ocenione poprzez porównanie ich z danymi referencyjnymi WorldCereal dostarczonymi przez ESA. W procesie oceny dokładności obliczono indeks Jaccarda. Indeks obliczono poprzez porównanie każdej maski danymi referencyjnymi. Dla zapewnienia większej dokładności oceny, uzyskane maski zostały także zweryfikowane w sposób wizualny, poprzez porównanie wyników ze zdjęciami satelitarnymi oraz z innymi maskami.

4. Wyniki

Analiza wyników obejmowała zarówno wizualną weryfikację delineacji jak i porównanie masek z warstwą referencyjną ESA WorldCereal (Fig 4.1). Stopień zgodności z danymi referencyjnymi obliczony został przy pomocy miary IoU (intersection over union), znanej również jako indeks Jaccarda [1]. Miara podobieństwa IoU jest jednym z podstawowych wskaźników w ocenie dokładności segmentacji jak również detekcji i śledzenia obiektów. Indeks Jaccarda obliczany jest według następującego wzoru, gdzie A i B są porównywanymi zbiorami:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$




Fig 4.1 Dane referencyjne ESA CropLand na tle zdjęcia satelitarnego.

W ramach wizualnej weryfikacji wyników postanowiono porównać tylko kilka wybranych zdjęć, ponieważ zdelinealizowane pola uprawne przy pomocy czterech wersji modeli podstawowych mają podobny wygląd a różnią się głównie tym jakie pola uprawne zostały wyznaczone. Podobnie wyglądają wyniki uzyskane przy pomocy dotrenowanych modeli.

4.1 NAIP

Wyniki delineacji pól uprawnych na zdjęciu pochodzącym z programu NAIP uzyskały wysoką dokładność zarówno przy użyciu modeli dotrenowanych jak i podstawowych. Na wykresie porównującym dokładność (Fig 4.2) można zauważyć, że każdy z modeli uzyskał ponad 80% dokładności. Każdy z dotrenowanych modeli uzyskał większą zgodność z danymi referencyjnymi niż podstawowa wersja modeli. Najmniejszą różnicę w dokładności zauważyć można dla modelu Base Plus (2%), natomiast największą w przypadku użycia modelu Large (12%).

Analizując wykres porównujący czas delineacji (Fig 4.3) można zauważyć, że użycie dotrenowanych modeli wiąże się ze zwiększonym czasem. Przy użyciu każdego z dotrenowanych modeli czas przetwarzania wzrósł o ponad 40% względem podstawowej wersji. Największą różnicę czasową zaobserwować można dla modelu Small (50%) a najmniejszą dla modelu Tiny (43%). Można także zauważyć, że dla obu wersji modelu czas delineacji wzrasta wraz z wielkością modelu.




Fig 4.2 Porównanie dokładności delineacji na danych NAIP




Fig 4.3 Porównanie czasu delineacji na danych NAIP

W ramach wizualnej oceny wyników segmentacji porównano dwa przykładowe zdjęcia. Na zdjęciu przedstawiającym wynik delineacji przy pomocy podstawowego modelu Base Plus (Fig 4.4) zauważyć można, że poligony są wewnętrznie podzielone na mniejsze części. Wewnątrz nich znajdują się także mniejsze, oddzielnie wyznaczone pola. Najczęściej ma to miejsce w miejscach, gdzie na polach uprawnych występują drzewa, budynki, drogi lub turbiny wiatrowe. Wyniki uzyskane za pomocą modeli dotrenowanych charakteryzują się poligonami o spójniejszej strukturze niż ma to miejsce przy zastosowaniu modeli podstawowych. Poligony pól uprawnych są większe i nie występuje w nich podział na mniejsze części, co można zauważyć na zdjęciu przedstawiającym wyniki uzyskane przy pomocy dotrenowanego modelu Base Plus (Fig 4.5). Występujące wewnątrz upraw drzewa, budynki czy turbiny wiatrowe zostały pominięte przez podczas segmentacji co można zaobserwować w postaci „dziur” w poligonach (Fig 4.5).




Fig 4.4 Wynik segmentacji zdjęcia NAIP przy użyciu podstawowego modelu Base Plus




Fig 4.5 Wynik segmentacji zdjęcia NAIP przy użyciu dotrenowanego modelu Base Plus.

Porównując wyniki segmentacji w powiększeniu (Fig 4.6) zauważyć można, że podstawowe modele mają tendencje do tworzenia małych, oddzielnych poligonów wewnątrz większych. Podstawowy model nie rozróżnia dobrze terenów uprawnych od dróg czy drzew. W prawym dolnym rogu zdjęć widać jak podstawowy model wyznaczył obszar drzew, natomiast dotrenowana wersja modelu nie uznała go jako część segmentacji.




Fig 4.6 Porównanie segmentacji przy użyciu podstawowego (po lewej) i dotrenowanego (po prawej) modelu small na danych NAIP.

4.2 Sentinel-2

Wyniki dokładności delineacji zdjęcia z satelity Sentinel-2 (Fig 4.7) za pomocą dotrenowanych modeli charakteryzują się wysoką zgodnością z danymi referencyjnymi (ok. 95%). Dokładność podstawowych modeli jest niższa i waha się od 74% do 79%. Najniższa dokładność delineacji zaobserwowana została przy użyciu podstawowego modelu Base Plus.

Czas delineacji (Fig 4.8) zarówno przy wykorzystaniu modeli dotrenowanych jak i podstawowych rośnie wraz z wielkością modeli. Porównując pary modeli dotrenowanych i nie, w każdym z przypadków delineacja przy użyciu dotrenowanej wersji była bardziej kosztowna czasowo. Najmniejszy wzrost nastąpił dla modelu Tiny i wynosił 6%, procentowy wzrost czasu zwiększa się wraz z wielkością modeli i dla największego modelu Large wynosił 13%.




Fig 4.7 Porównanie czasu delineacji na danych Sentinel-2




Fig 4.8 Porównanie czasu delineacji na danych Sentinel-2

Wizualna ocena poligonów zdelinealizowanych za pomocą podstawowego modelu Small (Fig 4.9) ukazuje, że została pominięta część pól natomiast takie obiekty jak drogi, drzewa czy rowy melioracyjne zostały wyznaczone. Wyniki uzyskane przy użyciu dotre-
nowanego modelu Small (Fig 4.10) odznaczają się tym, że obiekty zawarte wewnątrz pól
uprawnych są przeważnie pomijane, natomiast niektóre rowy melioracyjne są wyzna-
czone jako część pól uprawnych. Porównując rozmiar poligonów zauważyć można, że

podstawowy model tworzy mniejsze, wewnętrznie podzielone poligony. Poligony wyznaczone przez model dotrenowany są większe i spójne wewnętrznie.




Fig 4.9 Wynik segmentacji zdjęcia Sentinel-2 przy użyciu podstawowego modelu Small.




Fig 4.10 Wynik segmentacji zdjęcia Sentinel-2 przy użyciu dotreowanego modelu Small.

4.3 Landsat 8

W delineacji zdjęcia z satelity Landsat 8 można zauważyć największą różnicę w uzyskanych dokładnościach (Fig 4.11). Dokładność uzyskiwana przy pomocy dotrenowanego modelu jest wysoka, natomiast podczas zastosowania modelu Base Plus nastąpił duży spadek dokładności związany z przyjętym poziomem progu stabilności. Wyznaczenie pól przy pomocy podstawowych modeli daje różne wyniki dokładności zależne od wielkości modeli, modele o większym rozmiarze uzyskują większą dokładność niż te małe. Najniższą dokładność (3%) uzyskał dotrenowany model Base Plus, natomiast wśród podstawowych modeli nastąpiło to w przypadku modelu Tiny, gdzie dokładność delineacji wyniosła 34%.

Analizując wykres czasu delineacji zdjęcia (Fig 4.12) zauważyć można, że nie zawsze jest większy przy użyciu dotrenowanych modeli, zaobserwować można to przy użyciu modelu Base Plus oraz Large. Największą różnicę można zauważyć dla modelu Small, gdzie nastąpił wzrost o 10% przy użyciu modelu dotrenowanego. Można także zauważyć, że podstawowe modele wykazują tendencję do wzrostu czasu delineacji wraz z wielkością modeli.




Fig 4.11 Porównanie czasu delineacji na danych Landsat 8




Fig 4.12 Porównanie czasu delineacji na danych Landsat 8

Analizując wizualnie wyniki delineacji można zauważyć, że podstawowy model Large (Fig 4.13) wyznaczył większość pól uprawnych, różnice pomiędzy innymi podstawowymi modelami wynikają głównie w ilości wyznaczonych pól. Poligony tworzone przez wszystkie podstawowe modele są duże, nie można zauważyć w nich innych mniejszych części, obiekty w postaci drzew, turbin wiatrowych czy budynków często wyznaczone są jako część pól uprawnych. Wyniki uzyskane przy pomocy dotrenowanego modelu (Fig 4.14) pokazują generalizację procesu delineacji. Dotrenowane modele tworzą pojedyncze maski pokrywające prawie cały obszar, wyjątkiem jest model Base Plus, gdzie przez przyjęty próg stabilności model wyznaczył tylko małą część pól.



Fig 4.13 Wynik segmentacji zdjęcia Landsat 8 przy użyciu podstawowego modelu Large.



Fig 4.14 Wynik segmentacji zdjęcia Landsat 8 przy użyciu dotreowanego modelu Large.

Wynik dokładności delineacji przy pomocy dotrenowanego modelu Base Plus różnił się znacząco od innych modeli, dlatego postanowiono go poprawić poprzez obniżenie progu stabilności do 0,7. Przed obniżeniem progu wyznaczone zostały tylko niektóre pola uprawne (Fig 4.15), a ich kształt podobny jest do tych widocznych na delineacjach przy użyciu podstawowych modeli. Do obniżeniu progu stabilności model wyznaczył resztę pól uprawnych w podobny sposób jak przy użyciu innych dotrenowanych wersji, generalizując pozostały obszar i wyznaczając go jako jeden duży poligon (Fig 4.16).




Fig 4.15 Wynik segmentacji zdjęcia Landsat 8 przy użyciu dotrenowanego modelu Base Plus.



Fig 4.16 Wynik segmentacji zdjęcia Landsat 8 przy użyciu dotreowanego modelu Base Plus po przyjęciu progu stabilności na poziomie 0,7.

5. Wnioski

Model uczenia maszynowego Segmenta Anything Model 2 jest narzędziem o dużym znaczeniu w procesie segmentacji zdjęć satelitarnych. Połączenie modelu SAM 2 z pakietem Samgeo ułatwia i usprawnia jego wykorzystanie w dziedzinie teledetekcji i GIS. Stosując modele segmentacyjne praca w postaci wyznaczania obiektów na zdjęciach może zostać znacznie usprawniona, ręczne wyznaczanie w programach GIS takich obiektów jak pola uprawne jest procesem czasochłonnym. Stosując rozwiązania uczenia maszynowego delineacja pól uprawnych może zostać zautomatyzowana i przyspieszona.

Choć podstawowe modele dobrze radzą sobie z delineacją pól uprawnych, zasadnym może okazać się dotrenowanie modeli w celu polepszenia ich działania. Takie rozwiązanie pozwala na polepszenie efektów segmentacji przy pomocy SAM 2. Zdelinealizowane pola uprawne przy pomocy dotrenowanych modeli są zgodniejsze z faktycznymi granicami upraw oraz częściej w ich granicach nie są wyznaczane inne obiekty np. w postaci drzew, turbin wiatrowych, budynków czy rowów melioracyjnych. Wzrost dokładności pomiędzy stosowaniem modeli podstawowych a dotrenowanych przedstawiono w postaci tabeli (Tab 5.1). Podczas analizy modeli dotrenowanych zauważono, że podstawowe modele mają tendencję do wewnętrznego podziału pól uprawnych na mniejsze fragmenty, zastosowanie dotrenowanych modeli pozwoliło na pozbycie się tego efektu. Stosowanie dotrenowanych modeli przeważnie obarczone jest wzrostem czasu przetwarzania zdjęć, przedstawione zostało to w postaci tabeli (Tab 5.2).

Tab 5.1 Procentowy wzrost dokładności delinacji pomiędzy modelem podstawowym a dotrenowanym.

Zobrazowanie	Tiny	Small	Base	Large
NAIP	9.20	6.82	2.22	11.90
Sentinel-2	21.52	25.00	25.68	18.99
Landsat 8	179.41	46.15	-95.83	17.07

Tab 5.2 Procentowy wzrost czasu delinacji pomiędzy modelem podstawowym a dotrenowanym.

Zobrazowanie	Tiny	Small	Base	Large
NAIP	42.76	50.32	44.21	45.04
Sentinel-2	5.83	9.60	12.07	13.48
Landsat 8	1.50	9.86	-4.97	-3.95

Proces dotrenowania modeli SAM 2 w celu poprawy delinacji pól uprawnych wiąże się z koniecznością posiadania wysokojakościowych danych treningowych. Odpowiednia jakość danych jest kluczowym aspektem dotrenowania modeli. Obecnie jednym z największych takich zbiorów danych jest Fields of The World, udostępnia on dane w postaci binarnych masek przedstawiających pola uprawne oraz powiązanych z nimi zdjęciami satelitarnymi. Dane FTW swoim zakresem obejmują państwa z całego świata, natomiast jakość danych dla poszczególnych krajów znacząco się różni co może utrudniać ich wykorzystanie.

Analiza danych satelitarnych ściśle związana jest z problemem rozdzielczości przestrzennej zdjęć. Wykorzystanie zdjęć o większej rozdzielczości przestrzennej pozwala na uzyskanie wyższej dokładności kosztem czasu obliczeniowego. Podczas analizy modeli SAM 2 na zdjęciach o różnych rozdzielczościach zauważono duży wzrost czasu obliczeniowego powiązany ze wzrostem rozdzielczości obrazowań. Przetwarzanie zdjęcia wysokorozdzielczego pochodzącego z programu NAIP, o wielkości pikseli 0,6 m, było nawet 10 krotnie dłuższe niż podczas delinacji zdjęcia z satelity Sentinel-2. Pomiędzy czasem przetwarzania zdjęcia Sentinel-2 a zdjęciem z satelity Landsat 8 zauważono nawet 14 krotny wzrost czasu delinacji obrazowania Sentinel-2, o rozmiarze pikseli 10m w porównaniu do 30 m zdjęcia Landsat 8. Delinacja zdjęć o wyższych rozdzielczościach pozwala na uzyskanie większej dokładności i szczegółowości powstałych masek pól uprawnych poprzez pozbycie się z nich obiektów w postaci drzew, turbin wiatrowych, budynków czy dróg. Należy tutaj zwrócić uwagę na to, że podstawowe modele na

zdjęciach z programu NAIP i Sentinel-2 nadal wyznaczają obiekty różniące się od upraw, natomiast reprezentowane są one jako oddzielne regiony. W przypadku zastosowania do-trenowanych modeli zauważono skłonność do generalizacji, gdzie w zastosowaniu ich na-zobrazowaniu Landsat 8 tworzą one nawet maski o pojedynczym regionie zajmujący pra-wie cały obszar rolniczy.

Literatura

- [1]. Costa L. (2021). Further Generalizations of the Jaccard Index
- [2]. Kerner H. et al. (2024). Fields of The World: A Machine Learning Benchmark Dataset For Global Agricultural Field Boundary Segmentation
- [3]. Kirillov A. et al. (2023). Segment Anything
- [4]. Loshchilov L., Hutter F. (2019). Decoupled Weight Decay Regularization
- [5]. Jamil N. et al. (2008). Noise removal and enhancement of binary images using morphological operations
- [6]. Ravi N. et al. (2024). SAM 2: Segment Anything in Images and Videos. Meta
- [7]. Van Tricht K. et al. et al. (2023). WorldCereal: a dynamic open-source system for global-scale, seasonal, and reproducible crop and irrigation mapping
- [8]. Velastegui-Montoya A. (2023). Google Earth Engine: A Global Analysis and Future Trends
- [9]. Wu Q., (2020). geemap: A Python package for interactive mapping with Google Earth Engine
- [10]. Wu Q., Prado Osco L., (2023). samgeo: A Python package for segmenting geospatial data with the Segment Anything Model (SAM)

Materiały uzyskane z Internetu

- [11]. <https://dagshub.com/blog/image-embedding-benefits-use-cases-and-best-practices/> [dostęp: 18.01.2025]
- [12]. <https://landsat.gsfc.nasa.gov/satellites/landsat-8/> [dostęp: 18.01.2025]
- [13]. <https://www.copernicus.eu/en/news/news/observer-sentinel-2c-joins-copernicus-family> [dostęp: 18.01.2025]
- [14]. <https://www.datacamp.com/tutorial/sam2-fine-tuning> [dostęp: 18.01.2025]